

等待時間的機器學習方法 排隊場景預測

Athanasios I. Kyritsis 和 Michel Deriaz 資訊科學研究所 · GSEM/CUI 日內瓦大學 瑞士日內瓦

電子郵件：
{athanasios.kyritsis,
michel.deriaz}@unige.ch

摘要：實體排隊是許多提供服務或銷售商品的行業的現實。由於強制的空閒時間，排隊等候可能會給客戶帶來壓力和疲憊，並可能導致客戶滿意度下降。

排隊理論已被廣泛用於評估客戶等待時間、優化員工排班以及提高排隊系統針對可變服務需求的穩健性。

在本文中，我們正在探索需要排隊的多個行業如何從機器學習中受益，以預測客戶的等待時間。我們首先預測銀行隊列的等待時間，然後提出如何將流程推廣到更多產業並實現自動化。最初使用包含銀行排隊人員條目的公開資料集，在訓練完全連接的神經網路後，預測客戶等待時間的平均絕對誤差為 3.35 分鐘。然後，我們將展示一個管理不同場景和行業隊列的 Web 應用程式。隊列可以具有獨特的參數，並且系統可以適應每個隊列，因為它創建每個隊列經過優化訓練的神經網路來預測等待時間。

系統的使用和功能透過模擬器進行驗證。因此，機器學習被證明是預測等待時間的排隊理論的可行替代方案。

關鍵字機器學習、模式辨識、佇列系統、排隊分析、Web 應用程式。

一、引言及相關工作

當多人需要存取某個資源並且服務無法滿足需求等級時，就會出現排隊問題。一方面，在訪問與健康相關的寶貴資源時，排隊是不可避免的禍害，因為這些資源的空閒時間非常昂貴[1]。另一方面，即使為了這個目的，隊列也可能變得不必要的大，並且可能導致顧客長時間的空閒時間。時間是寶貴的資源，消費者在購買服務或商品時必須做出有關時間使用的決定[2]。

「時間就是金錢」的觀念由來已久，最早的記錄版本應歸功於古希臘的安提豐（約公元前 430 年）[3]。較長的等待時間和客戶不滿意之間也存在聯繫[4]，因此，行業應該努力更好地分配資源，以優化等待隊列。

多個行業使用排隊優化技術來改善客戶服務。在醫療保健領域，排隊模型用於提高醫院的資源利用率[5]，並進行權衡以提高醫療保健系統所提供服務的效率和品質[4]。在工作量大或有多個服務點的藥局中，排隊模型可以評估服務和等待時間[6]。在機場，排隊規劃對於安全控制和辦理登機手續至關重要 [7]。在日常生活活動中也可以觀察到排隊現象，例如在雜貨店付款、在餐廳等候餐桌或在快餐店等待點餐。雖然研究表明，在某些情況下，較長的等待時間有時可能會導致較高的消耗[8]，但大多數排隊場景將受益於隊列管理，以降低所用資源的成本（在人員成本和消費者等待時間方面）。

排隊論試圖透過數學分析來研究等待隊伍。該領域最早研究的問題涉及電話流量的擁塞，並由數學家 AK Erlang [9] 進行了研究。佇列可以被建模為先進先出 (FIFO) 節點，其中客戶端到達，可能等待一段時間，並在離開佇列之前需要一段時間由伺服器處理[10]。Kendall 符號 [11] 通常用於以 A/S/c 形式描述排隊節點，其中 A 是每次到達佇列之間的持續時間的機率分佈，S 是服務次數的機率分佈，c 是數量節點上的伺服器數量。使用排隊理論，佇列管理器的目標是透過保持佇列短、等待時間短（這可能意味著伺服器數量增加）和系統的經濟維護（這意味著保持伺服器數量少）。透過建立排隊模型，可以預測任意客戶端的等待時間，以及任意時刻的佇列長度。

機器學習技術和模擬模型也可用於處理排隊問題。與通常為患者提供的粗略估計相比，腫瘤科使用的回歸模型改進了每日放射治療預約的整體等待時間的預測[12]。機器學習也被用於另一個領域。

這項工作由 Innosuisse 共同資助。

預測放射學檢查的病人等待時間和設施延誤時間的研究[13]。模擬也可用於對排隊問題進行建模[14]。透過模擬客戶端到達和服務時間的不同分佈以及可變數量的可用伺服器，可以預測佇列系統的預期效能並針對特定場景對其進行最佳化。

多種企業排隊管理解決方案為企業提供管理佇列的工具，從而減少等待時間並提高服務效率。據我們所知，目前還沒有通用的排隊系統，任何人都可以建立任何人都可以加入的佇列。我們提出了 QueueForMe，這是一個任何人都可以註冊為創建者的系統，並透過定義該佇列特有的一組初始參數以及這些參數的回應選項來開啟佇列。例如，這樣的參數可以在機場排隊辦理登機手續的情況下的行李數量。加入佇列的每個客戶端都會回應所有必要的參數，並使用機器學習推斷客戶端的預期等待時間。

機器學習模型考慮了客戶端加入佇列的時間、客戶端在佇列中的位置、佇列可用伺服器的數量以及客戶端對上述附加參數的回應。該模型透過使用過去客戶端的數據不斷適應佇列模式的潛在變化。

本文的其餘部分安排如下。在第二節中，我們針對客戶在銀行等待服務的場景提出了一個基於神經網路的等待時間預測解決方案。然後，我們在第三章中提出了通用排隊系統，該系統可用於各個行業，並且在預測客戶的估計等待時間時可以利用佇列特定參數。我們用我們建構的模擬器驗證排隊系統的學習能力。最後，我們在第四節中總結我們的工作。

二. 銀行場景中的等待時間預測

1) 資料集：為了奠定如何利用機器學習來預測加入佇列的新客戶的等待時間的基礎，我們使用 Bishop 等人發布的資料集。[15]。該資料集包括有關尼日利亞奧貢州 3 家銀行在 4 週內形成和服務的佇列的資訊。總共報告了 52444 個客戶端，每筆記錄包括客戶端加入佇列的時間、等待時間、服務時間、系統總時間（等待時間+服務時間）。不幸的是，數據集中沒有報告伺服器的數量。從系統的吞吐量可以明顯看出，每種情況下伺服器的數量都大於零，但不知道這是否是一個恆定的數字。

資料集中沒有缺失值。等待時間變數表示每個使用者在獲得服務之前必須在佇列中等待的時間（以分鐘為單位），並且是我們的機器學習模型經過訓練來預測的輸出變數。

平均值為 13.18，中位數為 12，標準




圖 1. 客戶等待時間（以分鐘為單位）的直方圖。

偏差為 5.95 分鐘。資料集等待時間值的直方圖如圖 1 所示。

2) 資料預處理和特徵工程：根據給定的資料集，對於每個客戶端，我們計算了客戶端加入佇列時在佇列中等待的人數。為此，我們透過將等待時間與到達時間相加來計算每個客戶的佇列離開時間，然後計算新客戶加入佇列時尚未離開佇列的人數。圖 2 展示了排隊等候人數的直方圖。

從客戶端加入佇列的時間戳記中，我們提取了 3 個特徵：星期幾（範圍從 0 到 4，表示星期一到星期五）、小時（範圍從 8 到 14）和分鐘（範圍從 0 到 59）。我們使用平均值編碼（也稱為目標編碼）來對這 3 個現有分類特徵和目標變數中的新特徵進行編碼。

回歸任務的均值編碼的想法很簡單。

令 x 為分類變量， y 為目標變數。對於 x 中的每個不同元素，我們計算 y 中對應值的平均值。然後特徵向量中 x 的每個條目都被替換為對應的平均值。

總共，我們使用 4 個特徵作為建模的輸入：佇列中等待的人、星期幾、小時和分鐘，以及上述等待時間變數形成輸出。

3) 實驗設定：本研究提出的機器學習實驗，我們使用了 Python 3.7.3 和 Tensorflow 2.0.0-beta1。為了評估我們系統的效能，我們將可用資料集分為訓練集 (80%) 和測試集 (20%)，在訓練階段保持測試集完全不可見。由於神經網路的持續訓練能力，我們決定使用神經網路而不是其他機器學習模型。當收集到一批新的訓練資料時，現有的神經網路可以僅根據這些資料進行訓練，而無需定期對所有可用的訓練資料進行訓練。這對於佇列管理系統來說是理想的選擇，因為新資料始終如一。




圖 2. 排隊等候人數的直方圖。

正在生產中。

4) 結果：我們訓練了一個具有 2 個隱藏層的全連接神經網絡，第一個隱藏層有 12 個神經元，第二個隱藏層有 8 個神經元。我們使用了修正線性單元

(ReLU)[16]作為所有隱藏層的激活函數，Adam 優化演算法[17]用於基於訓練資料迭代更新網路權重。對所有相關超參數的詳盡調整超出了本文的範圍，並且使用了神經網路架構的常用預設值。

經過 500 個 epoch 的訓練後，測試集上的平均絕對誤差為 3.35 分鐘。進行估計

對於訓練模型的預測能力，我們正在與樸素平均值和樸素中位數模型進行比較；這些模型始終預測訓練集的平均等待時間和中位數等待時間。樸素平均模型的平均絕對誤差為 4.71 分鐘

測試集，樸素中位數誤差為 4.59 分鐘。

因此，我們的模型比樸素平均數模型提高了 28.9%，比樸素中位數模型提高了 27%

一。不幸的是，由於沒有有關已部署伺服器的信息，我們無法將我們的模型的預測性能與排隊理論產生的模型進行比較。

為了使我們的研究具有可重複性，我們在這裡分享用於當前研究測試的程式碼 (<https://doi.org/10.5281/zenodo.3378407>)。此分析中使用的資料集可在此處取得 (<https://doi.org/10.1016/j.dib.2018.05.101>)。

三. 提出通用排隊系統

1) QueueForMe：我們正在提議 QueueForMe，這是一個 Web 應用程式，允許每個人創建一個虛擬隊列，允許周圍的客戶端加入。QueueForMe 包含兩種類型的使用者：建立者和用戶端。創建者是需要登入我們的平台才能透過提供隊列名稱和描述來建立隊列的人。客戶端不需要任何平台憑證，可以搜尋

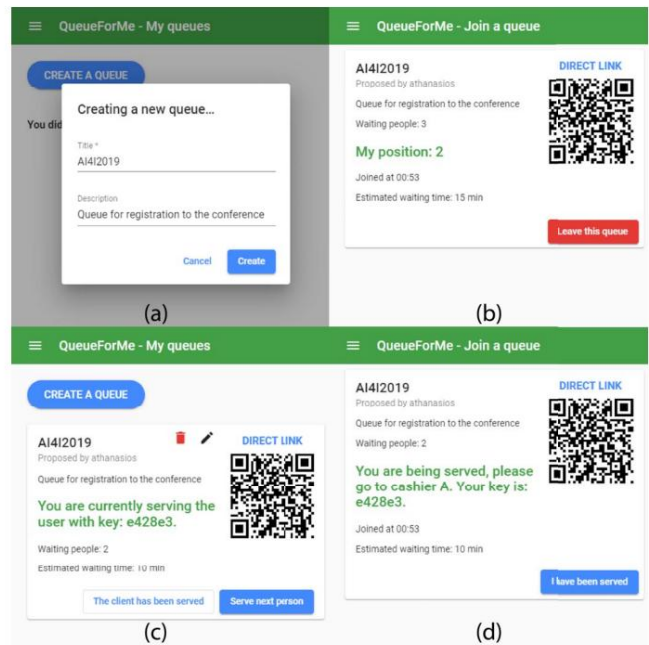


圖 3. 當 (a) 建立者正在建立新佇列、(b) 客戶端剛加入佇列、(c) 建立者正在為新客戶端提供服務以及 (d) 客戶端時，QueueforMe Web 應用程式的視圖正在由創作者服務。

透過隊列名稱或創建者名稱查找隊列，並最終可以加入隊列。加入隊列後，客戶端將獲取有關隊列的信息，包括隊列中的位置以及由使用過去的隊列數據為特定隊列訓練的神經網路預測的估計等待時間。創建者可以透過請求佇列中的下一個可用客戶端來操作佇列，並且對應的客戶端將收到要服務的通知。QueueForMe Web 應用程式的螢幕截圖如圖 3 所示。

2) 附加佇列參數：在 QueueForMe 的未來版本中，佇列的建立者將可以選擇定義一組佇列特定參數以及每個參數的受限回應集。加入佇列的客戶端必須對每個定義的參數給予回應。這些附加參數使我們的解決方案與眾不同，因為這種可自訂的附加參數在排隊理論中不存在，並且可以自動利用。每個特定隊列相應的神經網路將能夠提取更有價值的資訊並檢測這些參數之間的模式。

3) 模擬器：為了驗證每個隊列創建的每個神經網路的學習能力，我們開發了一個模擬器，用它來模擬顧客在特定時間內加入隊列。在我們的工具中，我們可以選擇新客戶加入隊列的分佈、可用線路的數量以及服務時間的分佈。然後，對隊列特定的神經網路進行重新訓練，從隊列中提供的模擬客戶中學習。經過訓練的模型還保存有關其預測性能的統計資料。的截圖

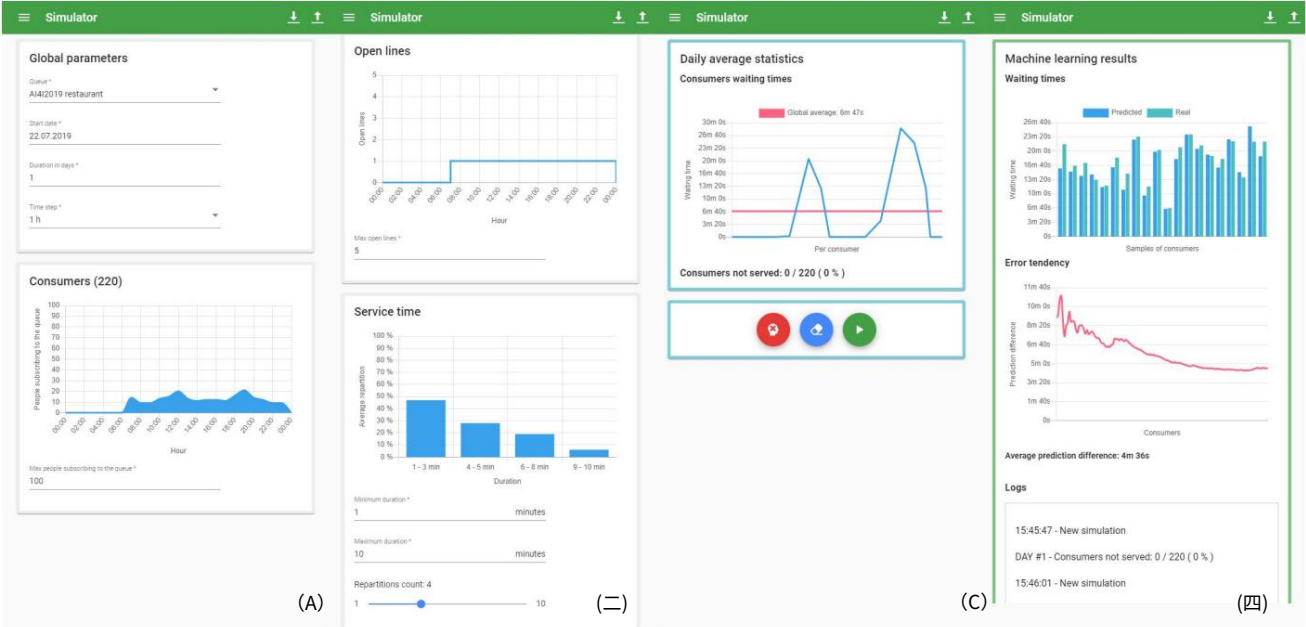


圖 4. 模擬器 Web 應用程式的視圖 (a) 設定全域佇列參數和客戶到達分佈 (b) 設定開放線路數量和服務時間分佈 (c) 顯示模擬資料集的平均統計資料和開始模擬 (d) 得到對應神經網路的誤差。

模擬器如圖4所示。

4) 產業特定佇列模擬 :在模擬器的未來版本中 ,我們還將包含如上所述的佇列特定附加參數 。每個佇列都會有一組預先定義的參數 ,每個參數都會有一組有效的回應 。使用模擬器 ,操作員將能夠模擬對每個參數的每個響應的不同分佈 。饋送到神經網路的新特徵將透過聚合與目前佇列相關的所有先前佇列的參數響應來設計 。

四 結論

在本文中 ,我們探討如何使用機器學習來預測排隊人員的等待時間 。我們首先使用銀行中公開發可用的佇列資料集 ,並透過訓練神經網路 ,我們實現了 3.35 分鐘的平均絕對誤差 ,從而提高了樸素模型的效能 。不幸的是 ,我們無法直接與排隊理論進行比較 ,因為資料集缺乏有關已部署伺服器的資訊 。

在介紹如何使用機器學習來預測排隊場景中的等待時間的具體案例之後 ,我們正在推廣到更多行業 。我們展示了我們在 QueueForMe 上的工作 ,這是一個 Web 應用程序 ,允許每個人創建虛擬佇列 ,並且周圍的每個人都可以加入 。使用模擬器 ,我們可以驗證佇列特定神經網路的預測能力 。作為未來的工作 ,我們將納入在佇列建立階段使用預定義回應來新增佇列特定參數的功能 。這些附加資訊將被底層等待時間預測所利用

可以使用模擬器模擬每個佇列的神經網路 ,以及每個參數響應的不同分佈 。

參考

[1] D. Worthington, “醫院等候名單的排隊模型”,《運籌學雜誌》,卷。38,沒有。5,第 413–422 頁,1987 年。

[2] C. Mogilner、H.E Hershfield 和 J. Aaker,“重新思考時間 :對幸福感的影響”,《消費者心理學評論》,第。1,沒有。1,第 41–53 頁,2018 年。

[3] B. Perrin,《普魯塔克的傳記》,系列。勒布古典圖書館。W.海涅曼,1920,沒有。v. 9. [線上].可用 :<https://books.google.ch/books?id=bSJgAAAAAAJ> [4] A. Komashie、A. Mousavi、P.J Clarkson 和 T. Young,“使用排隊理論的患者和工作人員滿意度綜合模型”,IEEE 健康與醫學轉化工程雜誌,卷。3,第 1–10 頁,2015 年。

[5] S. Belciug 和 F. Gorunescu,“通過排隊建模和進化計算提高醫院床位佔用率和資源利用率”,《生物醫學資訊學雜誌》,第。53,第 261–269 頁,2015 年。

[6] RA Nosek Jr 和 JP Wilson,“排隊理論和客戶滿意度 :術語、趨勢及其在藥學實踐中的應用回顧”,醫院藥學,第 1 卷。36,沒有。3,第 275–279 頁,2001 年。

[7] R. De Neufville、L. Budd 和 S. Ison,“機場系統規劃與設計”,航空運輸管理 :國際視角,卷。2016 年 61 日。

[8] S. Ulku、C. Hydock 和 S. Cui,“讓等待變得有價值 :排隊對消費影響的實驗”,管理科學,2019 年。

[9] AK Erlang,“概率論和電話交談”,尼特。Tidsskr。墊。序列。B,卷。20,第 33–39 頁,1909 年。

[10] JF Shortle、JM Thompson、D. Gross 與 CM Harris,《排隊論基礎》,約翰威利父子公司,2018 年,卷。399。

[11] DG Kendall,“隊列理論中發生的隨機過程及其通過嵌入馬可夫鍵方法的分析”,《數理統計年鑑》,第 338–354 頁,1953 年。

- [12] A. Joseph、T. Hijal、J. Kildea、L. Hendren 和 D. Herrera, “使用機器學習預測放射腫瘤學中的等待時間”, 2017 年第 16 屆 IEEE 國際機器學習和應用會議 (ICMLA)。IEEE, 2017 年, 第 1024–1029 頁。
- [13] C. Curtis、C. Liu、T.J. Bollerman 和 OS Pinykh, “用於預測患者等待時間和預約延遲的機器學習”, 美國放射學院雜誌, 第。 15、沒有。 9, 第 1310–1316 頁, 2018 年。
- [14] M. Bahadori、SM Mohammadnejhad、R. Ravangard 和 E. Tey-mourzadeh, 「使用排隊理論和模擬模型來最佳化醫院藥局績效」, 《伊朗紅新月會醫學期刊》, 第 1 卷。 16、沒有。 2014 年 3 月。
- [15] SA Bishop、HI Okagbue、PE Oguntunde、AA Opanuga 和 O. Odetunmbi, “尼日利亞奧貢州一些選定銀行隊列分析的調查數據集”, 數據簡介, 卷。 19, 第 835–841 頁, 2018 年。
- [16] AF Agarap, “使用修正線性單元 (relu) 進行深度學習”, arXiv 預印本 arXiv:1803.08375, 2018。
- [17] DP Kingma 和 J. Ba, “Adam : 一種隨機最佳化方法”, arXiv 預印本 arXiv:1412.6980, 2014。